

A Review of Unify Diffusion Model Theory Based on EDM

Created by Zeng zhiwen

Reference: [Elucidating the Design Space of Diffusion-Based Generative Models](#)

前向：通用加噪公式与SDE的相互转化

从一个分布 \mathbf{x}_0 到另一个分布 \mathbf{x}_t 的桥梁，也即流（Flow）：

$$p(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; s(t)\mathbf{x}_0, s^2(t)\sigma^2(t)\mathbf{I}) \quad (1)$$

将公式（1）进行重参数化采样，这里的 $\sigma(t)$ 为噪声强度的相对系数， $s(t)\sigma(t)$ 为绝对噪声强度（即噪声实际标准差）：

$$\mathbf{x}_t = s(t)\mathbf{x}_0 + s(t)\sigma(t)\epsilon \quad (2)$$

- $s(t)\mathbf{x}_0$ 为信息部分：

$$\text{信号功率} = \mathbb{E}[\|s(t)\mathbf{x}_0\|^2] = s(t)^2 \cdot \mathbb{E}[\|\mathbf{x}_0\|^2] = s(t)^2 \cdot \alpha \cdot n$$

- $s(t)\sigma(t)\epsilon$ 为噪声部分：

$$\text{噪声功率} = \mathbb{E}[\|s(t)\sigma(t)\epsilon\|^2] = s(t)^2\sigma(t)^2 \cdot \mathbb{E}[\|\epsilon\|^2] = s(t)^2\sigma(t)^2 \cdot n$$

- 信噪比：

$$SNR(t) = \frac{\alpha}{\sigma^2(t)}$$

为了适配EDM统一框架输入：

$$\hat{\mathbf{x}}_t = \frac{\mathbf{x}_t}{s(t)} = \mathbf{x}_0 + \sigma(t)\epsilon$$

最终单步递推公式（见 [#证明1](#)）：

$$\mathbf{x}_t = \frac{s(t)}{s(t-1)}\mathbf{x}_{t-1} + s(t)\sqrt{\sigma(t)^2 - \sigma(t-1)^2}\epsilon_t$$

$$\mathbf{x}_t = \sqrt{1 - \beta_t}\mathbf{x}_{t-1} + \sqrt{\beta_t}\epsilon$$

其中， $s(t) = \sqrt{\bar{\alpha}_t}$ ， $\bar{\alpha}_t = \prod_{s=1}^t(1 - \beta_s)$ ， $\sigma(t) = \sqrt{\frac{1 - \bar{\alpha}_t}{\bar{\alpha}_t}}$

对应的随机微分方程（SDE），形式如下：

$$d\mathbf{x}_t = f(t)\mathbf{x}_t dt + g(t)dw_t \quad (3)$$

反之，递推式可通过求取极限（见 [#证明2](#)）得到公式（3），对应系数如下：

$$s(t) = e^{\int_0^t f(r)dr} \quad (4)$$

$$f(t) = \frac{s'(t)}{s(t)}$$

$$\sigma^2(t) = \int_0^t \frac{g^2(r)}{s^2(r)} dr \quad (5)$$

$$g(t) = s(t) \sqrt{2 \cdot \sigma(t) \sigma'(t)}$$

公式 (2) 与公式 (3) 是等价的，公式 (4) 和 (5) 是沟通二者的桥梁，即起点分布相同条件下（即原图像 \mathbf{x}_0 ），针对特定加噪时间点 t ，公式 (3) SDE 的解 \mathbf{x}_t 与公式 (1) 采样获得的 \mathbf{x}_t 在分布上是一致的。特别地，EDM 框架令 $s(t) = 1$ ， $\delta(t) = t$ ，保证了时间和噪声水平完全等价。

模型：通用模型框架

EDM 概括了所有扩散模型中，神经网络部分的模型框架：

$$D_\theta(\hat{\mathbf{x}}; \sigma) = C_{skip}(\sigma) \hat{\mathbf{x}} + C_{out}(\sigma) F_\theta(C_{in}(\sigma) \hat{\mathbf{x}}; C_{noise}(\sigma)) \quad (6)$$

- $D_\theta(\hat{\mathbf{x}}; \sigma)$ 是接收一个规范化后的噪声图片（即原始图片 \mathbf{x}_0 直接添加 σ 水平的噪声，不进行尺度缩放得到的 $\hat{\mathbf{x}}$ ），以及我们为其指定的噪声水平 σ ，输出降噪后的“纯净图像”
 - 但是直接训练一个纯净网络效果不佳，因此 F_θ （残差）才是真正的网络组成。
 - $\hat{\mathbf{x}} = \frac{\mathbf{x}}{s(t)}$ ，用于统一所有模型的输入尺度
- C_{skip}, C_{out} ：纯净去噪网络 $D_\theta(\hat{\mathbf{x}}; \sigma)$ 的输出由噪声图片 $\hat{\mathbf{x}}$ 和模型 F_θ 输出加权组成。
- C_{in} ：用于适配不同网络对标准输入 $\hat{\mathbf{x}}$ 的系数，如 $s(t)$ 。
- C_{noise} ：EDM 要求模型框架 $D_\theta(\hat{\mathbf{x}}; \sigma)$ 的输入为 σ ，但不同模型真正输入 F_θ 的参数可能为 σ 的函数，因此需要作变换。

VP

$$D_\theta(\hat{\mathbf{x}}; \sigma) = \underbrace{1 \cdot \hat{\mathbf{x}}}_{c_{skip}} \underbrace{- \sigma}_{c_{out}} \cdot F_\theta \left(\underbrace{\frac{1}{\sqrt{\sigma^2 + 1}}}_{c_{in}} \cdot \hat{\mathbf{x}}; \underbrace{(M-1) \sigma^{-1}(\sigma)}_{c_{noise}} \right)$$

VE

$$D_\theta(\hat{\mathbf{x}}; \sigma) = \underbrace{1 \cdot \hat{\mathbf{x}}}_{c_{skip}} + \underbrace{\sigma}_{c_{out}} \cdot F_\theta \left(\underbrace{1 \cdot \hat{\mathbf{x}}}_{c_{in}}; \underbrace{\log \left(\frac{1}{2} \sigma \right)}_{c_{noise}} \right)$$

注意：这里的 VE $\hat{x} = x$

训练：通用训练框架

训练的过程，是针对从原始图像集合中采样得到的真实图像 \mathbf{x}_0 ，进行一次 σ 级别的噪声添加，得到 $\mathbf{x}_0 + \mathbf{n}$ ，随后可构造损失函数：

$$\mathcal{L}_{diff} = \mathbb{E}_{\sigma, \mathbf{n}, \mathbf{x}_0} \left[\lambda(\sigma) \|D_\theta(\hat{\mathbf{x}}; \sigma) - \mathbf{x}_0\|_2^2 \right] \quad (7)$$

$$\mathcal{L}_{diff} = \underbrace{\mathbb{E}_{\sigma, \mathbf{n}, \mathbf{x}_0}}_{P_{train}} \left[\underbrace{\lambda(\sigma) C_{out}^2(\sigma)}_{\text{损失权重}(\sigma)} \underbrace{\|F_\theta(C_{in}(\sigma) \cdot (\mathbf{x}_0 + \mathbf{n}); C_{noise}(\sigma))\|_2^2}_{\text{模型输出}} - \underbrace{\frac{1}{C_{out}(\sigma)} \|\mathbf{x}_0 - C_{skip}(\sigma) \cdot (\mathbf{x}_0 + \mathbf{n})\|_2^2}_{\text{训练目标}} \right]$$

- $\sigma \sim P_{train}$ ，即前向噪声采样分布，由各个模型决定
- $\mathbf{n} \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$ ， $\mathbf{x}_0 \sim P_{data}$
- $Var(\mathbf{x}_0) = \sigma_{data}^2$
- C_{in} ：保证神经网络的输入保持单位方差（式117）

$$c_{in}(\sigma) = \frac{1}{\sqrt{\sigma^2 + \sigma_{data}^2}}$$

- C_{out}, C_{skip} : 保证训练目标保持方差恒为1, 同时让 C_{out}^2 被最小化, 防止模型误差被放大 (式138、131):

$$C_{skip}(\sigma) = \frac{\sigma_{data}^2}{\sigma_{data}^2 + \sigma^2}$$

$$C_{out}(\sigma) = \frac{\sigma \cdot \sigma_{data}}{\sqrt{\sigma^2 + \sigma_{data}^2}}$$

- $\lambda(\sigma)$: 保证损失权重 $w(t) = 1$ (式 144):

$$\lambda = \frac{\sigma^2 + \sigma_{data}^2}{(\sigma \cdot \sigma_{data})^2}$$

- 当初始化神经网络权重为0 (即输出恒0), 方差暂时固定某个初始值时, 有:

$$\mathbb{E}(\mathcal{L}) = 1$$

- σ 调度: EDM认为, 损失函数在加噪水平很低或很高情况下, 损失函数均难以下降, 因此训练噪声调度的选择如下:

$$\ln(\sigma) \sim \mathcal{N}(P_{mean}, P_{std}^2)$$

其中 $P_{mean} = -1.2, P_{std} = 1.2$

- 对于 VP, 其训练调度为面向 t 的均匀分布:

$$\beta(t) = (\beta_{max} - \beta_{min})t + \beta_{min}, \quad t \sim \mathcal{U}(\epsilon_t, 1)$$

- 对于 VE, 其训练调度与EDM同样面对 σ 进行, 但是为均匀调度:

$$\ln(\sigma) \sim \mathcal{U}(\ln(\sigma_{min}), \ln(\sigma_{max}))$$

VP

$$\underbrace{\mathbb{E}_{\sigma^{-1}(\sigma) \sim \mathcal{U}(\epsilon_t, 1)}}_{p_{train}} \mathbb{E}_{\mathbf{x}_0, \mathbf{n}} \left[\underbrace{\frac{1}{\sigma^2}}_{\text{损失权重}} \left\| D_{\theta}(\mathbf{x}_0 + \mathbf{n}; \sigma) - \mathbf{x}_0 \right\|_2^2 \right]$$

VE

$$\underbrace{\mathbb{E}_{\ln(\sigma) \sim \mathcal{U}(\ln(\sigma_{min}), \ln(\sigma_{max}))}}_{p_{train}} \mathbb{E}_{\mathbf{x}_0, \mathbf{n}} \left[\underbrace{\frac{1}{\sigma^2}}_{\text{损失权重}} \left\| D_{\theta}(\mathbf{x}_0 + \mathbf{n}; \sigma) - \mathbf{x}_0 \right\|_2^2 \right]$$

- 二者的损失权重均随噪声减小而增大, 即后期精细降噪过程给与更多关注

$$\hat{\mathbf{x}} = \mathbf{x}_0 + \mathbf{n} = \frac{\mathbf{x}}{s(t)}$$

损失类型	数学形式	适用场景
残差损失	$\ D_{\theta}(\hat{\mathbf{x}}) - \mathbf{x}_0\ ^2$	直接去噪
噪声损失	$\ F_{\theta}(\mathbf{x}) - \epsilon\ ^2$	DDPM 类模型
分数匹配	$\ N_{\theta}(\mathbf{x}) - \nabla \log p(\mathbf{x})\ ^2$	基于分数的生成模型

- D_{θ} 是逐步去噪后的结果, 可能导致误差积累, 而直接预测比较简单的单步噪声分布 F_{θ} 更为容易学习。

反向：通用推理过程

通用 概率流常微分方程 PFODE

► 通用反向：对于任意一个扩散模型加噪SDE（公式(3)），通过福克普朗克方程，可进一步推导出一个常微分方程（ODE），也叫概率流常微分方程（PFODE）：

$$d\mathbf{x}_t = \left[f(t)\mathbf{x}_t - \frac{1}{2}g^2(t) \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) \right] dt \quad (8)$$

注意，这里的 $p_t(\mathbf{x}_t)$ 可以描述为：

$$\begin{aligned} p_t(x) &= \int_{\mathcal{R}^d} p_{0t}(x|x_0)p_{data}(x_0)dx_0 \\ &= s(t)^{-d} [p_{data} * \mathcal{N}(0, \sigma^2(t)\mathbf{I})](\mathbf{x}/s(t)) \\ &= s(t)^{-d} p(\mathbf{x}/s(t); \sigma(t)) \end{aligned}$$

- * 表示卷积操作
- $\mathbf{x}/s(t)$ 表示分布在此处的取值

$$\begin{aligned} \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) &= \nabla_{\mathbf{x}} \log s(t)^{-d} + \nabla_{\mathbf{x}} \log [p_t(\frac{\mathbf{x}_t}{s(t)}; \sigma(t))] = \nabla_{\mathbf{x}} \log [p_t(\frac{\mathbf{x}_t}{s(t)}; \sigma(t))] \\ &= \frac{1}{s(t)} \nabla_{\hat{\mathbf{x}}} \log p(\hat{\mathbf{x}}; \sigma(t)) = \frac{1}{s(t)\sigma^2(t)} (D_{\theta}(\hat{\mathbf{x}}; \sigma(t)) - \hat{\mathbf{x}}) \end{aligned} \quad (10)$$

分数函数的方向由当前噪声图谱 $\hat{\mathbf{x}}$ （低概率密度）指向神经网络预测的真实的分布 $\mathcal{D}_{\theta}(\hat{\mathbf{x}}; \sigma(t))$ （高概率密度）

► 通用反向：因此，在确定起点 \mathbf{x}_0 （前向）或 \mathbf{x}_N （逆向）前提下，式（8）解的分布 $p(\mathbf{x}_t)$ ，即 \mathbf{x}_t 的边缘概率密度与加噪过程SDE求解得到的分布是完全相同：

$$d\mathbf{x}_t = \left[\left(\frac{\dot{\sigma}(t)}{\sigma(t)} + \frac{\dot{s}(t)}{s(t)} \right) \mathbf{x}_t - \frac{\dot{\sigma}(t)s(t)}{\sigma(t)} D_{\theta}(\frac{\mathbf{x}_t}{s(t)}; \sigma(t)) \right] dt \quad (11)$$

说明：针对PFODE，当dt取反时，便可实现前向加噪和后向加噪的切换，因此式（8）、式（9）、式（11）都可以兼顾前向和反向的描述，但**不可用PFODE实现图像加噪**，因为PFODE在给定起点时，其终点是确定的，于是变形成非分布的一对一输入输出样本匹配对。扩散模型建模的是真实分布与完全噪声分布之间的关系，必须通过随机采样配对实现，因此不能用PFODE实现图像加噪，而是仅能用于反向采样去噪

通用确定性采样

公式（11）的 \mathcal{D}_{θ} 可用神经网络模拟，具体为公式（6），随后通过使用ODE求解器，如一阶Euler，二阶Heun，在给定起点 \mathbf{x}_N 下，逐步采样获得生成图像。**注意：训练过程的时间步和采样过程的时间步定义不同**，EDM采样过程的噪声水平定义为：

$$\sigma_{i < N} = \left(\sigma_{max}^{\frac{1}{\rho}} + \frac{i}{N-1} (\sigma_{min}^{\frac{1}{\rho}} - \sigma_{max}^{\frac{1}{\rho}}) \right)^{\rho} \text{ and } \sigma_N = 0 \quad (12)$$

VP (DDPM / DDIM)

VP(Variance Perserving) ，噪声调度满足 **信号与噪声的方差总和恒定**，前向公式：

$$\begin{aligned} \mathbf{x}_t &= \sqrt{1 - \beta_t} \mathbf{x}_{t-1} + \sqrt{\beta_t} \epsilon \\ \mathbf{x}_t &= \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon \\ \hat{\mathbf{x}}_t &= \frac{\mathbf{x}_t}{\sqrt{\bar{\alpha}_t}} = \mathbf{x}_0 + \frac{\sqrt{1 - \bar{\alpha}_t}}{\sqrt{\bar{\alpha}_t}} \epsilon \\ d\mathbf{x} &= -\frac{1}{2} \beta(t) \mathbf{x} dt + \sqrt{\beta(t)} d\mathbf{w} \end{aligned} \quad (16)$$

对离散递推式取极限可以直接导出连续式（16）。

VP一步加噪式中的 $\bar{\sigma} = \sqrt{1 - \bar{\alpha}_t}$ 表示原框架下的图谱噪声，其融合了尺度缩放项 $s(t)$ ，而在同一框架下， $\sigma(t)$ 才是前向过程所叠加的噪声标准差：

$$\begin{aligned} \bar{\sigma}(t) &= \sqrt{1 - \bar{\alpha}_t} \\ s(t) &= \sqrt{\bar{\alpha}_t} \\ \sigma(t) &= \frac{\sqrt{1 - \bar{\alpha}_t}}{\sqrt{\bar{\alpha}_t}} \end{aligned}$$

满足

$$s(t) = \frac{1}{\sqrt{\sigma^2(t) + 1}}$$

上面的符号与式（2）对应。

漂移项 $f(t)$:

$$f(t) = -\frac{1}{2} \beta(t)$$

扩散项 $g(t)$:

$$g(t) = \sqrt{\beta(t)} \quad (18)$$

式（17）、式（18）带入式（b）得到**VP逆向SDE**过程:

$$\begin{aligned} d\mathbf{x} &= \frac{1}{2} \beta(t) \sigma(t)^2 \nabla_{\mathbf{x}} \log p(\mathbf{x}) dt + \sqrt{\beta(t)} d\mathbf{w} \\ &= \left[-\frac{1}{2} \beta(t) \mathbf{x} - \beta(t) \nabla_{\mathbf{x}} \log p(\mathbf{x}) \right] dt + \sqrt{\beta(t)} d\mathbf{w} \end{aligned} \quad (19)$$

VE (SMLD)

VE(Variance Exploding)，VE过程的噪声调度允许 **噪声方差无限增长**，前向公式：

$$\begin{aligned} \mathbf{x}_t &= \mathbf{x}_{t-1} + \sqrt{\sigma^2(t) - \sigma^2(t-1)} \epsilon \\ \mathbf{x}_t &= \mathbf{x}_0 + \sigma(t) \epsilon \\ d\mathbf{x} &= \sqrt{\frac{d\sigma^2(t)}{dt}} d\mathbf{w} \end{aligned} \quad (20)$$

其中， $\bar{\sigma}(t) = s(t) \cdot \sigma(t) = \sigma(t)$

扩散项：

$$g(t) = \sqrt{\frac{d\bar{\sigma}^2(t)}{dt}} = \sqrt{\frac{d\sigma^2(t)}{dt}} \quad (22)$$

漂移项:

$$f(t) = 0$$

带入式（a）得到与song等人定义一致的**VE**逆向过程：

$$\begin{aligned} d\mathbf{x} &= [-g(t)^2 \nabla_x \log p_t(\mathbf{x})]dt + g(t)d\mathbf{w} \\ &= \left[-\frac{d\sigma^2(t)}{dt} \nabla_x \log p_t(\mathbf{x})\right]dt + \sqrt{\frac{d\sigma^2(t)}{dt}}d\mathbf{w} \end{aligned} \tag{23}$$

附录

【补充1】 如何理解 VP 方差保持与 VE 方差爆炸

考虑**VP**递推：

$$x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\epsilon$$

由方差性质：

$$Var(x_t) = \alpha_t Var(x_{t-1}) + (1 - \alpha_t) \cdot 1$$

由数学归纳法，假设 $Var(x_{t-1}) = 1$ ，有：

$$Var(x_t) = \alpha_t + 1 - \alpha_t = 1$$

因此方差是保持的。

而**VE**中， $Var(x_t) = 1 - \alpha_t = \beta_t$ ，由于噪声水平逐步增大，因此方差是爆炸式增大的。

【补充2】 DDPM与VP的关系

DDPM是**VP**的离散化形式

模型	前向加噪公式
VP SDE	$d\mathbf{x} = -\frac{1}{2}\beta(t)\mathbf{x}dt + \sqrt{\beta(t)}d\mathbf{w}$
DDPM	$\begin{aligned} \mathbf{x}_t &= \sqrt{1 - \beta_t}\mathbf{x}_{t-1} + \sqrt{\beta_t}\epsilon \\ \mathbf{x}_t &= \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon \end{aligned}$

模型	反向采样公式
VP SDE	$d\mathbf{x} = [-\frac{1}{2}\beta(t)\mathbf{x} - \beta(t)\nabla_x \log p_t(x)]dt + \sqrt{\beta(t)}d\bar{\mathbf{w}}$
DDPM	$\begin{aligned} \mathbf{x}_{t-1} &= \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \beta_t \frac{\epsilon_{\theta}(\mathbf{x}_t, t)}{\sqrt{1 - \bar{\alpha}_t}} \right) + \sqrt{\beta_t}\epsilon_t \\ \mathbf{x}_{t-1} &= \frac{1}{\sqrt{1 - \beta_t}} \left(\mathbf{x}_t + \beta_t \frac{D_{\theta}(\frac{\mathbf{x}_t}{s(t)}; \sigma(t)) - \frac{\mathbf{x}_t}{s(t)}}{s(t)\sigma^2(t)} \right) + \sqrt{\beta_t}\epsilon_t \end{aligned}$

VP中的变量定义与转化

- $\alpha_t = 1 - \beta_t$
- $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$

在实践中，有如下近似：

$$\log \bar{\alpha}_t = \sum_{i=1}^t \log \alpha_i \approx \int_0^t \log(1 - \beta_s) ds$$

这里的 $\log(1 - \beta_s) \approx -\beta_s$ ，表示在0处的泰勒展开
因此

$$\bar{\alpha}_t \approx \exp\left(-\int_0^t \beta_s ds\right)$$

β_t 在实践中被定义为时间线性函数

$$\begin{aligned} \beta(t) &= (\beta_{\max} - \beta_{\min})t + \beta_{\min} \\ \int_0^t \beta_s ds &= \int_0^t (\beta_{\min} + s(\beta_{\max} - \beta_{\min})) ds = \beta_{\min} t + \frac{t^2}{2}(\beta_{\max} - \beta_{\min}) \end{aligned}$$

故

$$\bar{\alpha}_t = \exp(-\beta_{\min} t + \frac{t^2}{2}(\beta_{\max} - \beta_{\min}))$$

3. $\bar{\sigma}(t) = s(t)\sigma(t) = \sqrt{1 - \bar{\alpha}_t}$ ，即原框架下 t 时刻的图像噪声水平

4. $s(t) = \sqrt{\bar{\alpha}_t}$ ，与式 (2) 对应

5. $\sigma(t) = \frac{\sqrt{1 - \bar{\alpha}_t}}{\sqrt{\bar{\alpha}_t}}$ ，与式 (2) 对应

【其他】

1. EDM前向

$$\begin{aligned} \mathbf{x}_t &= \mathbf{x}_{t-1} + \sqrt{\sigma^2(t) - \sigma^2(t-1)}\epsilon \\ \mathbf{x}_t &= \mathbf{x}_0 + \sigma(t)\epsilon \\ d\mathbf{x} &= \sqrt{\frac{d\sigma^2(t)}{dt}} d\mathbf{w} \end{aligned}$$

与VE一致，但噪声分布不同：

$$\ln(\sigma(t)) = \ln(t) \sim \mathcal{N}(P_{mean}, P_{std}^2)$$

2. Wiener过程

$w_t \sim \mathcal{N}(0, t)$ 是一个布朗运动（Wiener）过程

- 独立增量性： $w_{t+\Delta t} - w_t$ 与 w_t 独立
- 布朗运动的增量服从正态分布： $w_{t+\Delta t} - w_t \sim \mathcal{N}(0, \Delta t)$
- 令 $\Delta t \rightarrow 0, d_w \sim \mathcal{N}(0, d_t)$
 - 布朗运动无穷小增量的平方 $d_w^2 = d_t$ 为确定性质量
 - 重参数化展开： $d_w = \sqrt{d_t} \cdot \epsilon, \epsilon \sim \mathcal{N}(0, 1)$

3. EDM论文相关

Song et al. present a stochastic differential equation (SDE) that **maintains** the desired distribution p as sample \mathbf{x} evolves over time

若一个SDE的解 \mathbf{x}_t 的边际分布 p_t 满足：

$$\lim_{t \rightarrow \infty} p_t(\mathbf{x}) = p(\mathbf{x}) \quad \text{且} \quad \text{一旦达到 } p \text{ 后, 分布不再随时间变化}$$

则称 p_t 是该SDE的**不变分布**（或稳态分布）。此时，SDE“保持”了分布 p_t 。

- **正向过程：**

从数据分布 p_{data} 出发，通过SDE逐渐将数据破坏为噪声分布纯粹的高斯分布 ϵ 。

- **逆向过程：**

从噪声 ϵ 出发，通过SDE将样本演化回 p_{data} 。

To specify the ODE, we must first choose a schedule $\sigma(t)$ that defines the desired noise level at time t .

在PFODE中， $\sigma(t)$ **直接表示 t 时刻数据的噪声水平（累积结果）**，而非单步添加量。这样一来，在前向加噪训练时，针对某一时刻 t 噪声水平 $\sigma(t)$ ，直接向 \mathbf{x}_0 添加 $\mathcal{N} \sim (0, \sigma^2(t))$ 的高斯随机噪声即可。在反向降噪采样时，也可以直接告诉神经网络当前图像的噪声水平 $\sigma(t)$ ，从而做出**相应力度**的降噪操作。

The score function has the remarkable property that it does not depend on the generally intractable normalization constant of the underlying density function $p(\mathbf{x}; \sigma)$

Score Function它不依赖于概率密度函数 $p(\mathbf{x}; \sigma)$ 的归一化常数（normalization constant）。

假设概率密度函数可以分解为：

$$p(x; \sigma) = \frac{1}{Z(\sigma)} \tilde{p}(x; \sigma)$$

其中：

- $\tilde{p}(x; \sigma)$ 是未归一化的概率密度（可能难以计算积分）。
- $Z(\sigma)$ 是归一化常数（通常难以计算，尤其是高维数据）。

取对数后：

$$\log p(x; \sigma) = \log \tilde{p}(x; \sigma) - \log Z(\sigma)$$

计算梯度时：

$$\nabla_x \log p(x; \sigma) = \nabla_x \log \tilde{p}(x; \sigma) - \underbrace{\nabla_x \log Z(\sigma)}_{=0}$$

由于 $Z(\sigma)$ 不依赖 x ，其梯度为零，因此：

$$\nabla_x \log p(x; \sigma) = \nabla_x \log \tilde{p}(x; \sigma)$$

结论： Score 函数仅依赖于未归一化的 $\tilde{p}(x; \sigma)$ ，与 $Z(\sigma)$ 无关！

Excessive Langevin-like addition and removal of noise results in gradual **loss of detail** in the generated images. There is also a drift toward oversaturated colors at very low and high noise levels. We suspect that practical denoisers induce a slightly nonconservative vector field.

引入随机性（SDE，朗之万噪声步骤）虽然能修正早期采样误差，但会导致**细节丢失**和在极端噪声水平下的颜色过饱和。

原因可能在于：

- Denoiser的过渡去噪移除了比理论值更多的噪声，破坏了朗之万扩散所需的保守向量场；
- \mathcal{L}^2 损失使得模型倾向于预测均值，忽略极端边缘细节

解决方案在于：

- 限制噪声添加的时机范围 $t_i \in [S_{t_{min}}, S_{t_{max}}]$
- 使得每次添加随机噪声的水平 S_{noise} 略微大于1抵消细节损失

- 确保每次新增噪声的强度不超过当前图像的噪声水平，防止过度破坏结构

【证明1】前向离散一步加噪式（2）转化为离散单步递推式

离散一步加噪形式：

$$\mathbf{x}_t = s(t)\mathbf{x}_0 + s(t)\sigma(t)\epsilon$$

假设：

$$\mathbf{x}_t = \alpha_t \mathbf{x}_{t-1} + \beta_t \epsilon_t$$

1. 期望匹配：

$$\mathbb{E}[\mathbf{x}_t] = s(t)\mathbf{x}_0 = \alpha_t \mathbb{E}[\mathbf{x}_{t-1}] = \alpha_t s(t-1)\mathbf{x}_0$$

因此：

$$\alpha_t = \frac{s(t)}{s(t-1)}$$

2. 方差匹配：

$$\text{Var}(\mathbf{x}_t) = s(t)^2 \sigma(t)^2 = \alpha_t^2 \text{Var}(\mathbf{x}_{t-1}) + \beta_t^2$$

代入 $\text{Var}(\mathbf{x}_{t-1}) = s(t-1)^2 \sigma(t-1)^2$ ：

$$\beta_t^2 = s(t)^2 \sigma(t)^2 - \left(\frac{s(t)}{s(t-1)} \right)^2 s(t-1)^2 \sigma(t-1)^2 = s(t)^2 (\sigma(t)^2 - \sigma(t-1)^2)$$

因此：

$$\beta_t = s(t) \sqrt{\sigma(t)^2 - \sigma(t-1)^2}$$

3. 最终单步递推公式：

$$\mathbf{x}_t = \frac{s(t)}{s(t-1)} \mathbf{x}_{t-1} + s(t) \sqrt{\sigma(t)^2 - \sigma(t-1)^2} \epsilon_t \quad (24)$$

【证明2】前向加噪离散形式到连续形式的转化

原始递推式如下：

$$\mathbf{x}_t = \frac{s(t)}{s(t-1)} \mathbf{x}_{t-1} + s(t) \sqrt{\sigma(t)^2 - \sigma(t-1)^2} \epsilon_t$$

两边减去 \mathbf{x}_{t-1} ，并写为极限形式：

$$\mathbf{x}_t - \mathbf{x}_{t-\Delta t} = \left(\frac{s(t)}{s(t-\Delta t)} - 1 \right) \mathbf{x}_{t-\Delta t} + s(t) \sqrt{\sigma(t)^2 - \sigma(t-\Delta t)^2} \epsilon_t.$$

当时间步长 $\Delta t = t - (t-1) \rightarrow 0$ 时：

(1) 对 $s(t-\Delta t)$ 进行泰勒展开

$$\begin{aligned} s(t-\Delta t) &\approx s(t) - s'(t)\Delta t + \mathcal{O}(\Delta t^2) \\ \frac{s(t)}{s(t-\Delta t)} &\approx \frac{s(t)}{s(t) - s'(t)\Delta t} \approx 1 + \frac{s'(t)}{s(t)} \Delta t \\ \left(\frac{s(t)}{s(t-\Delta t)} - 1 \right) &\approx \frac{s'(t)}{s(t)} \Delta t \end{aligned}$$

当 $\Delta t \rightarrow 1$ 令：

$$f(t) = \left(\frac{s(t)}{s(t-1)} - 1 \right) \approx \frac{s'(t)}{s(t)}$$

(2)对 $\sigma^2(t - \Delta t)$ 泰勒展开

$$\sigma(t - \Delta t)^2 \approx \sigma(t)^2 - \frac{d}{dt}[\sigma(t)^2]\Delta t$$

因此

$$\sigma(t)^2 - \sigma(t - \Delta t)^2 \approx 2\sigma(t)\sigma'(t)\Delta t$$

当 $\Delta t \rightarrow 1$

$$\sigma(t)^2 - \sigma(t-1)^2 \approx 2\sigma(t)\sigma'(t)$$

因此

$$g(t) = s(t)\sqrt{\sigma(t)^2 - \sigma(t-1)^2}\epsilon_t = s(t)\sqrt{2\sigma(t)\sigma'(t)}$$

【证明3】VE 前向离散形式推导

$$dx = \sqrt{\frac{d^2\sigma(t)}{dt}}dw_t$$

由欧拉离散化 $x_t = x_{t-1} + dx(t-1)$ ：

$$x_t = x_{t-1} + \sqrt{\frac{\sigma^2(t) - \sigma^2(t-1)}{\Delta t}}\sqrt{\Delta t}\epsilon$$

令 $\Delta t = 1$ 得：

$$x_t = x_{t-1} + \sqrt{\sigma^2(t) - \sigma^2(t-1)}\epsilon$$

由迭代求和可得：

$$x_t = x_0 + \sigma(t)\epsilon$$

特别地， $\sigma(t) = \sigma_{\min}(\frac{\sigma_{\max}}{\sigma_{\min}})^t$ ，其中 $t \sim \mathcal{U}(0, 1)$

也可由式（24）通式带入相关项得到。

【证明4】VP 前向离散形式推导

$$d\mathbf{x}_t = -\frac{1}{2}\beta(t)\mathbf{x}_tdt + \sqrt{\beta(t)}dw_t$$

欧拉离散化：

$$\mathbf{x}_t = \mathbf{x}_{t-1} + (-\frac{1}{2}\beta(t)\mathbf{x}_{t-1}\Delta t + \sqrt{\beta(t)}\sqrt{\Delta t}\epsilon)$$

令 $\Delta t = 1$ ，得：

$$\mathbf{x}_t = (1 - \frac{1}{2}\beta(t))\mathbf{x}_{t-1} + \sqrt{\beta(t)}\epsilon$$

泰勒展开近似有： $\sqrt{1 - \beta(t)} = 1 - \frac{1}{2}\beta(t)$ 得：

$$\mathbf{x}_t = \sqrt{1 - \beta(t)}\mathbf{x}_{t-1} + \sqrt{\beta(t)}\epsilon$$

递推求和得, $\sigma(t)^2 = 1 - e^{-\int_0^t \beta(s)ds}$:

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$$

特别地, $\beta(t) = (\beta_{max} - \beta_{min})t + \beta_{min}$, 其中, $t \sim \mathcal{U}(\epsilon_t, 1)$

给定VP逆向SDE:

$$d\mathbf{x} = \left[-\frac{1}{2}\beta(t)\mathbf{x} - \beta(t)\nabla_x \log p_t(\mathbf{x}) \right] dt + \sqrt{\beta(t)} d\bar{\mathbf{w}}$$

(1) 忽略扩散项

$$d\mathbf{x} = \left[-\frac{1}{2}\beta(t)\mathbf{x} - \beta(t)\nabla_x \log p_t(\mathbf{x}) \right] dt$$

(2) 欧拉离散化

对时间 (t) 离散化, 步长 Δt , 逆向时间从 (t) 到 (t-1):

$$\mathbf{x}_{t-1} = \mathbf{x}_t + \left[-\frac{1}{2}\beta_t \mathbf{x}_t - \beta_t \nabla_x \log p_t(\mathbf{x}_t) \right] (-\Delta t)$$

令 $\Delta t = 1$

$$\mathbf{x}_{t-1} = \mathbf{x}_t + \frac{1}{2}\beta_t \mathbf{x}_t + \beta_t \nabla_x \log p_t(\mathbf{x}_t)$$

(3) 得分函数替换 (残差形式):

$$\nabla_x \log p_t(\mathbf{x}_t) \approx -\frac{\epsilon_\theta(\mathbf{x}_t, t)}{\sqrt{1 - \bar{\alpha}_t}} = \frac{1}{s(t)\sigma^2(t)} (D_\theta(\frac{\mathbf{x}_t}{s(t)}; \sigma(t)) - \frac{\mathbf{x}_t}{s(t)})$$

- 这里 ϵ_θ 表示噪声方向
- 前者为噪声预测形式, 后者为残差形式。
- $\sqrt{1 - \bar{\alpha}_t} = \bar{\sigma}_t$
- \mathbf{x}_t 表示原模型输入 F_θ 的形式

直观理解: 分母 $\sqrt{1 - \bar{\alpha}_t} = s(t)\sigma(t)$, 分子量纲为 $\sigma(t) \cdot \epsilon_\theta$, 因此需要再除一份 $\sigma(t)$

(3') 得分函数替换 (噪声形式):

$$\begin{aligned} \mathbf{x}_{t-1} &= \mathbf{x}_t + \frac{1}{2}\beta_t \mathbf{x}_t - \beta_t \frac{\epsilon_\theta(\mathbf{x}_t, t)}{\sqrt{1 - \bar{\alpha}_t}} \\ \mathbf{x}_{t-1} &= \left(1 + \frac{1}{2}\beta_t\right) \mathbf{x}_t - \beta_t \frac{\epsilon_\theta(\mathbf{x}_t, t)}{\sqrt{1 - \bar{\alpha}_t}} \end{aligned}$$

此处 $1 + \frac{1}{2}\beta_t$ 泰勒展开近似

$$\mathbf{x}_{t-1} \approx \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \sqrt{\alpha_t} \beta_t \frac{\epsilon_\theta(\mathbf{x}_t, t)}{\sqrt{1 - \bar{\alpha}_t}} \right)$$

由于 β_t 近似0, $\alpha_t = 1 - \beta_t$ 近似1, 因此 $\sqrt{\alpha_t} \beta_t \approx \beta_t$

(4) 加入随机噪声

噪声预测形式:

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \beta_t \frac{\epsilon_\theta(\mathbf{x}_t, t)}{\sqrt{1 - \bar{\alpha}_t}} \right) + \sqrt{\beta_t} \epsilon_t$$

残差预测形式:

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{1-\beta_t}} \left(\mathbf{x}_t + \beta_t \frac{D_\theta(\frac{\mathbf{x}_t}{s(t)}; \sigma(t)) - \frac{\mathbf{x}_t}{s(t)}}{s(t)\sigma^2(t)} \right) + \sqrt{\beta_t} \epsilon_t$$

【证明6】VE 反向形式离散化推导过程

由VE反向连续SDE形式：

$$d\mathbf{x} = \sqrt{\frac{d\sigma^2(t)}{dt}} d\mathbf{w}_t$$

可知

$$g(t) = \sqrt{\frac{d\sigma^2(t)}{dt}}$$

对VE反向SDE连续形式欧拉离散化：

$$\begin{aligned} d\mathbf{x} &= [-g(t)^2 \nabla_x \log p_t(\mathbf{x})] dt + g(t) d\mathbf{w} \\ \mathbf{x}_{t-1} &= \mathbf{x}_t + d\mathbf{x}_t = \mathbf{x}_t + \frac{d^2\sigma_t}{dt} \cdot \frac{\epsilon_\theta(\mathbf{x}_t, t)}{\bar{\sigma}_t} + \sqrt{\frac{d^2\sigma_t}{dt}} \sqrt{dt} \epsilon_t \end{aligned}$$

进一步，令 $\Delta t = 1$ ：

$$\mathbf{x}_{t-1} = \mathbf{x}_t + \frac{\sigma_t^2 - \sigma_{t-1}^2}{\bar{\sigma}_t} \epsilon_\theta(\mathbf{x}_t, t) + \sqrt{\sigma_t^2 - \sigma_{t-1}^2} \epsilon_t$$

由于 $\bar{\sigma}(t) = \sigma(t)$ ，因此：

噪声预测形式：

$$\mathbf{x}_{t-1} = \mathbf{x}_t + \frac{\sigma_t^2 - \sigma_{t-1}^2}{\sigma_t} \epsilon_\theta(\mathbf{x}_t, t) + \sqrt{\sigma_t^2 - \sigma_{t-1}^2} \epsilon_t$$

残差预测形式：

$$\mathbf{x}_{t-1} = \mathbf{x}_t - (\sigma_t^2 - \sigma_{t-1}^2) \frac{1}{s(t)\sigma^2(t)} (D_\theta(\frac{\mathbf{x}_t}{s(t)}; \sigma(t)) - \frac{\mathbf{x}_t}{s(t)}) + \sqrt{\sigma_t^2 - \sigma_{t-1}^2} \epsilon_t$$

由于 $s(t) = 1$ ，有：

$$\mathbf{x}_{t-1} = \mathbf{x}_t - \frac{(\sigma_t^2 - \sigma_{t-1}^2)}{\sigma_t^2} (D_\theta(\mathbf{x}_t; \sigma_t) - \mathbf{x}_t) + \sqrt{\sigma_t^2 - \sigma_{t-1}^2} \epsilon_t$$

实践

VP

- 训练
 - 时间调度： $t \sim \mathcal{U}(\epsilon_t, 1)$
 - 噪声调度： $\sigma(t) = \sqrt{e^{\frac{1}{2}\beta_d t^2 + \beta_{\min} t} - 1}$
 - 损失权重： $\lambda(\sigma) = \frac{1}{\sigma^2}$
- 采样
 - 时间调度： $t \sim 1 + \frac{i}{N-1}(\epsilon_s - 1)$
 - 噪声调度： $\sigma(t) = \sqrt{e^{\frac{1}{2}\beta_d t^2 + \beta_{\min} t} - 1}$

VE

- 训练
 - 时间调度: $t \sim \mathcal{U}(\ln(\sigma_{min}), \ln(\sigma_{max}))$
 - 噪声调度: $\sigma(t) = \sigma_{min}(\frac{\sigma_{max}}{\sigma_{min}})^t$, 人为定义
 - 损失权重: $\lambda(\sigma) = \frac{1}{\sigma^2}$
- 采样
 - 时间调度: $t \sim \sigma_{max}^2 (\frac{\sigma_{min}^2}{\sigma_{max}^2})^{\frac{i}{N-1}}$
 - 噪声调度: \sqrt{t} , 理论值

VE、EDM采用的是基于sigma的均匀分布采样训练，需要避免极端噪声

VP采用的是基于时间均匀分布的采样训练，可以覆盖全部时间范围